

修士卒業論文

遺伝的アルゴリズムと深層強化学習に基づく
ジョブスケジューリング最適化問題
—PCB加工プロセスをモデルとして—

Job Scheduling Optimization Based on Genetic Algorithms and Deep Reinforcement Learning
—A Model of the PCB Manufacturing Process—

関西学院大学大学院
総合政策研究科
汪 永豪
2026 年 1 月

要旨

近年、市場グローバル化が進む中、製品に対する市場ニーズは多様化しており、顧客ごとに仕様が異なる多品種少量生産方式への対応が重要となっている。本研究では、プリント基板 (PCB) 製造工場を対象に、同一加工機械を複数回使用する生産プロセスをモデル化した上で、スケジューリング最適化に関する検討を行った。静的な環境においては、遺伝的アルゴリズム (GA) および深層強化学習に基づく Deep Q-Network(DQN) を用いて最適化を行い、両手法の性能比較を実施した。さらに、機械故障等による環境変動が発生する動的な環境で高速にスケジュールを生成可能な DQN により、適応性能の向上を図った。これらから静的および動的な生産環境におけるスケジューリングを検討する。

キーワード：インダストリーエンジニアリング、オペレーション・リサーチ、ジョブスケジューリング最適化問題、遺伝的アルゴリズム、深層強化学習

Abstract

In recent years, as market globalization has advanced, market demands for products have become increasingly diversified, making it essential to respond to high-mix, low-volume production systems in which specifications differ for each customer. This study focuses on a printed circuit board (PCB) manufacturing factory and models a production process in which identical processing machines are used multiple times. Based on this model, scheduling optimization is investigated. Under a static production environment, this study applies a genetic algorithm (GA) and a Deep Q-Network (DQN) based on deep reinforcement learning to perform scheduling optimization, and conducts a comparative evaluation of the performance of these two methods. Furthermore, under a dynamic production environment where environmental changes such as machine failures occur, this study aims to improve adaptability by utilizing DQN, which can generate schedules rapidly in response to such changes. Through these approaches, this study examines scheduling optimization for both static and dynamic production environments.

Keywords : Industry Engineering, Operations Research, Job Shop Scheduling Optimization Problem, Genetic Algorithm, Deep Reinforcement Learning

目 次

要旨	1
Abstract	1
目次	2
1. はじめに	3
2. 先行研究	3
3. 生産管理問題のモデル	4
3.1 モデル設定	4
3.2 問題設定	5
4. 実験用データ自動生成ルール	6
4.1 データ自動生成の考え方	6
4.2 データ生成手続き	8
4.3 データ生成結果	9
5. 遺伝的アルゴリズムによる解の改善	9
5.1 遺伝的アルゴリズムの考え方	9
5.2 PPS 交差法の考え方	10

遺伝的アルゴリズムと深層強化学習に基づく ジョブスケジューリング最適化問題 —PCB加工プロセスをモデルとして—

Job Scheduling Optimization Based on Genetic Algorithms and Deep Reinforcement Learning
—A Model of the PCB Manufacturing Process—

汪 永豪^{*1} 山田 孝子^{*2}
Wang Yonghao Takako Yamada

^{*1}関西学院大学大学院総合政策研究科

Graduate School of Policy Studies, Kwansei Gakuin University

^{*2}関西学院大学総合政策学部メディア情報学科

Department of Applied Informatics, School of Policy Studies, Kwansei Gakuin University

1. はじめに

世界経済のグローバル化に伴い、製造業企業は他社より安い価格で注文を受ける必要がある。いかにして低コストな生産システムと高品質な品質管理を両立させ、安定的に維持するかは、製造業が必ず直面すると言って過言ではない難しい問題である。昨今ではこの両立にさらに安全管理を含むワークライフバランスを考えた労務管理が加わり、生産現場では達成すべき課題が複雑化している。コスト削減のため、多くの企業は人間作業員の代わりに、製造工程のロボットを採用し、工場内物流には複積載搬送ロボット (AGV) の導入をすすめている。AGV の導入により生産機械間の半製品や仕掛品の運搬は自動化された。生産計画には、スケジューリングだけではなく、AGV の搬送計画も含まれ、経路や運搬すべき半製品の決定までを生産計画に含むことになった。本研究では、以下のシステムを順次作成し、生産管理計画システムとして実装し、最適解を求める計算機実験を実施、システムの性能を検証した。

本研究でこれまで行ったことをまとめる

1. 実験用ジョブセットとして、製品種別ごとの加工機械の利用順番、利用時間の組み合わせデータの自動生成システムの作成
2. 生成されたデータを用いた生産機械のスケジューリングを総当たり法で厳密解を求める最短生産スケジュール算出システムの作成
3. 生産スケジュールの可視化システムの作成
4. 遺伝的アルゴリズムをベースとする、緩和手法による許容解算出と解の改善システムの作成
5. 生産機械に加え複数台 AGV を導入した生産スケジュールの最適化システムの作成
6. 求められた生産スケジュールに基づく生産機械の遊休時間活用する余剰生産品提案システムの作成

以上を行ったうえで、本研究では機械と AGV 両方向同時スケジューリングを求め、現有的仕事を最短時間で終了する許容解を導出し、その許容解のもとで、機械の遊休時間を活用する余剰製品を提案するシステムの開発に取り組む。このような問題は、JSSP (Job Shop Scheduling Problem) 問題と言います。

2. 先行研究

グローバル経済の進展や企業のコスト削減要求に伴い、生産現場では柔軟で効率的な生産体制の構築が求められている。その中で、需要の多様化に対応するために、少量多品種生産が一般的となり、このような生産形態に適したスケジューリングの最適化が重要な課題となっている。特に、ジョブショップスケジューリング問題 (Job Shop Scheduling Problem: JSSP) は、生産システムにおける代表的な最適化課題として広く研究されている。JSSP は、複数のジョブを限られた機械に割り当て、全体の処理時間や納期遅延を最小化することを目的とする問題である。また、各ジョブには処理順序が定められており、この順序を厳密に守る必要がある点が特徴である。この問題は NP 困難であり、最適解を求めることは計算量的に非常に困難である。そのため、これまで多くの研究では、遺伝的アルゴリズム (Genetic Algorithm: GA) や焼きなまし法 (Simulated Annealing: SA) などのヒューリスティック手法を用いて、効率的に近似解を求めるアプローチが提案されてきた。しかし、実際の製造現場では、機械の故障や新規ジョブの追加、処理時間の変動など、動的な要素が頻繁に発生する。そのような動的環境下では、あらかじめ定められたルールに

基づくヒューリスティック手法では十分に対応できない場合がある。この問題を解決するため、近年では強化学習 (Reinforcement Learning: RL) を用いて、環境変化に応じて自律的にスケジューリング方策を学習する手法が注目されている。静的な環境においては GA や SA などの伝統的アルゴリズムが一定の成果を上げている一方で、動的な生産環境では強化学習に基づくアプローチのほうが、より高い適応性と柔軟性を示すことが報告されている。このように、JSSP におけるスケジューリング最適化の研究は、従来の探索型手法から学習型手法へと発展しつつある。

実際に、近年の研究ではこの流れを反映した多様なアプローチが報告されている。K.T. Chung ら [1] は現在工業 5.0 の時代に向けて、機械学習、特に強化学習を用いて、CO(combinatorial optimization) 問題を解決しようについて、現在の研究進展を述べた。M. Xu ら [2] は遺伝的プログラミングと強化学習を統合的に整理・比較し JSSP スケジュール最適化問題において果たす役割と近年の研究動向を明らかにした。C. Ngwu ら [3] は動的な JSSP 問題は強化学習や進化的ヒューリスティック、機械学習を用いた手法でリアルタイムな意思決定は可能であることを示しました。X.R. Shao ら [4] は小規模かつ短時間の JSSP 問題に対して、多層畳み込みニューラルネットワーク (ML-CNN) と反復局所探索 (ILS) を組み合わせ、ML-CNN で全体経路を学習し、ILS で最適な局所経路を探索する手法が提案された。L.B. Wang ら [5] は機械故障や再作業などの動的な環境での JSSP 問題について深層強化学習 (DRL) を用いた動的スケジューリング手法が提案され、PPO により最適な方策を学習することで、リアルタイムな生産スケジューリングが可能であることが示された。S. Lee ら [6] は射出成形金型製造プロセスにおいて、Deep Q-Network を活用することで従来より総加重遅延を低減できる金型生産スケジューリングを最適化した。C. Pickardt ら [7] は半導体製造プロセスにおいて、遺伝的プログラミング (GP) と確率的離散事象シミュレーションを組み合わせることで自動的に従来のルールより性能優れたルールを生成した。村山ら [8] は JSSP 問題に基づき、加工機械と複数積載型 AGV の同時スケジューリングを対象とした遺伝的アルゴリズム (GA) 手法が提案された。

これらの研究から、JSSP およびその拡張問題に対して、静的環境ではヒューリスティック手法、動的環境では強化学習や深層学習手法が有効であることが確認されている。

3. 生産管理問題のモデル

本研究は受注生産を行う工場の製造工程をモデル化する。受注型ジョブショップスケジュール問題 (Job Shop Scheduler problem: JSSP) に関する最適化問題であることで、事前にクライアント側からもらった注文書は不可欠なデータだ。

本研究は、実際のプリント基板 (PCB) 製造工場をモデルとした研究であり、本来であれば使用する注文書データは実生産に基づくものであることが望ましい。しかしながら、PCB 製造に関する実データは、企業の営業機密や顧客情報に直結するため、企業との共同研究等がない限り、その入手は極めて困難である。そこで本研究では、先行研究に記載されている PCB 製造工程を参考にし、各加工機械に対して加工役割を割り当てることで、PCB 製造プロセスをモデル化する。また、PCB の種類によって必要とされる加工時間、加工工程数、あるいは加工順序が異なることを考慮し、これらの差異をモデル内に反映させている。本研究では PCB を製品として定義する。例えば製品 1 は PCB の種類 1、製品 2 は PCB 板の種類 2 を表すものとする。まとめて注文書をセットし、ジョブセットと呼ばれる。JSSP のスケジュール最適化対象と見られる。なお、各機械の機能割り当ておよび加工製品に関する工程設定の詳細については、次章において述べる。

これから制限条件に書かれている符号の定義とモデル設定を紹介する。

3.1 モデル設定

1. 注文票はさまざまな注文主からくる。
2. 各注文書には製品 J の種別が 1 種類以上が記載されている。
3. 注文書ごとに製品ごとロット数が記載されている。
4. 工場は、注文書 O_i をまとめ、これをジョブセットとする。
5. 製造する製品種別に応じて、使用する加工機械、加工時間とその加工機械の使用順が予め与えられる。
6. 工場はジョブセットで同一出荷として受注した注文書を加工生産時間を最短にし、加工機械の最適なスケジューリングを行う。
7. 機械は注文書に記載された製品種別で指定された注文個数をすべて加工が終了するまで、作業を途中で終えたり、途中で他の製造作業を行うような割り込みはできないものとする。
8. 製品種別が異なるための機械のセットアップタイムは考慮しない。
9. 製品の加工間の搬送時間はこのモデルでは考慮しない。
10. 一つの機械は一つの加工工程のみ作業する。
11. 機械は製品種別ごとに定まる順番の通りに機械を使用して加工作業を行わなければならない。
12. 製品ごとに全部の加工工程が終了したら、その製品の加工スケジューリングが終了する。
13. 全部の製品の加工スケジューリングが終了したら、ジョブセットのスケジューリングが終了する

表 1: 本研究に用いる記号の定義

記号	説明
O	工場が受領した注文書の集合
O_i	第 i 番に工場が受領した注文書
J_s	製品 J の種別番号 s
$O_i J_s$	第 i 注文書に記載されたジョブ J の種別番号 s
$lot J_{i,s}$	第 i 注文書に記載された第 s 種別製品の注文ロット数
n_s	対象ジョブセットに記載された第 s 種別製品の合計注文個数
n_s	$10 \sum_{i=1}^{\infty} lot J_{i,s}$ (個数 = ロット数 $\times 10$)
$J_s F_q$	第 s 種別製品の第 q 番目の加工工程
$m_{s,q}$	第 s 種別製品の第 q 工程に割り当てられる機械番号
M	使用可能な加工機械の集合
M_m	第 m 番加工機械
$t_{s,q}$	第 s 種別製品の第 q 工程に要する加工時間
$ft_{s,q}$	第 s 種別製品の第 q 工程の完了時刻
$ft_{m_{s,q}}$	機械 $m_{s,q}$ 上で直前に処理された工程の完了時刻
TJ_s	第 s 種別製品の加工終了時間
$makespan$	全製品種別における最終工程完了時刻の最大値
OM	各加工工程の機械割当を表す行列
$m_{s,q} = OM_{s,q}$	機械割当行列の要素定義
OT	各加工工程の加工時間を表す行列
$t_{s,q} = OT_{s,q}$	加工時間行列の要素定義
C	制約条件の集合

3.2 問題設定

本研究は、JSSP を制約付き最適化問題として定式化し、目標関数としては:

$$\text{opt. } JSSP = \min \left\{ \max_s TJ_s \right\} \quad (1)$$

ここで、 TJ_s は第 s 種別製品の最終加工工程の完了時刻を表す。したがって、本最適化問題は、全ての製品種別における最終完了時刻の最大値、すなわち $makespan$ を最小化することを目的とする。

制約条件としては:

$$\text{s.t. } C1: ft_{s,q} \geq ft_{s,q-1} + t_{s,q} \quad (2)$$

$$\text{s.t. } C2: ft_{s,q} \geq ft_{s',q'} + t_{s,q} \quad (3)$$

制約条件 $C1$ は、同一製品種別 J_s における隣接する加工工程 F_{q-1} と F_q の加工順序制約を表しており、前工程が完了した後でなければ次工程を開始できないことを意味する。

制約条件 $C2$ における $ft_{s',q'}$ は、加工工程 $J_{s'} F_{q'}$ と同じ機械 $m_{s,q}$ を使用するが、製品種別が異なる別製品 $J_{s'}$ の加工工程 $J_{s'} F_{q'}$ の完了時刻を表す。すなわち、 $ft_{s',q'}$ は、同一機械上で $J_s F_q$ の直前に処理された工程の完了時刻に対応する。

制約条件 $C2$ は、各加工機械は同時刻に一つの加工工程しか処理できないという機械リソース制約を表しており、ある工程が機械 M_m 上で処理中の場合、次の工程はその加工工程が終了するまで開始できない。

JSSP においては、加工工程と加工機械の対応関係を表す機械割当行列 OM と、各加工工程に要する加工時間を表す加工時間行列 OT が既知である。 OM と OT に関することは次章に述べる。

各製品種別の加工順序が与えられた場合、各加工工程 $J_s F_q$ の完了時刻は次の式に基づいて算出することができる。

$$ft_{s,q} = \max (ft_{s,q-1}, ft_{m_{s,q}}) + t_{s,q} \quad (4)$$

ここで、 $ft_{s,q}$ は第 s 種別製品の第 q 加工工程の完了時刻を表す。本式は、各加工工程の完了時刻が、同一製品における直前工程の完了時刻 $ft_{s,q-1}$ と、同一加工機械 $m_{s,q}$ 上で直前に処理された別製品工程の完了時刻 $ft_{m_{s,q}}$ のいずれか遅い方に、加工時間 $t_{s,q}$ を加えた値として決定されることを示している。

ジョブショップスケジューリングの目的は、各加工機械をできるだけ連続的に稼働させるとともに、各製品の加工工程を待ち時間なく加工することにより、総加工時間を最小化することである。したがって、JSSP は待機している加工機械に対して加工対象となるジョブを割り当てる逐次意思決定問題として見られる。スケジューリング過程は、加工機械上で各加工工程の処理完了イベントによって駆動される。同一製品内における加工工程の順序制約および、各加工工程が指定された加工機械で加工されなければならないという制約を考慮すると、待機中の加工機械に製品の加工工程を割り当てる際には、現時点で処理可能な加工工程が存在

するかどうかを判断する必要がある。処理可能な加工工程の集合が複数存在する場合には、その中から一つを選択して加工を開始する。一方、現時点で処理可能な加工工程が存在しない場合には、次の加工工程完了イベントが発生するまで待機する。この意思決定過程は次の図 1 に示します。

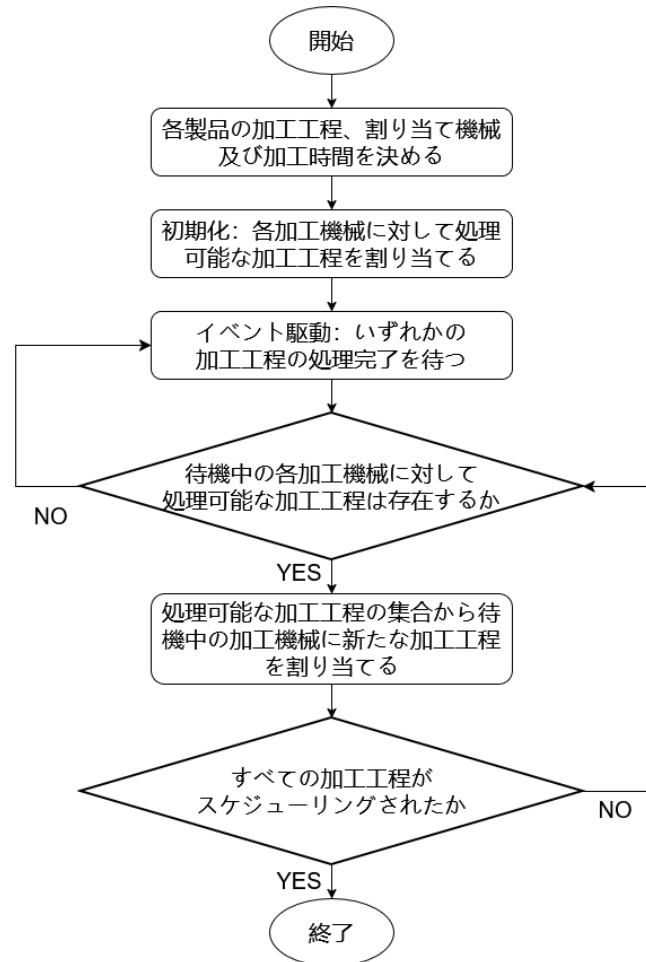


図 1: ジョブスケジューリング問題フローチャート

4. 実験用データ自動生成ルール

本研究では、実際の PCB 製造工場をモデルとしたスケジューリング問題を対象とする。本来であれば、行列 *OM* および *OT* に用いる機械加工順序データや加工時間データは、実工場から取得した実績データに基づくことが望ましい。しかしながら、個々の製品の加工順序や加工時間、注文書などの生産情報は企業の営業機密および顧客情報に関連しており、企業と共同研究等がない限り、入手することは困難である。そこで本研究では、文献 [22] に記載された多層 PCB の製造工程に基づく、各製品種別ごとの加工工程と使用機械を仮定、その上で注文書のばらつきやロット構成を確率モデルにより生成することで、実工場を模擬した実験用データを自動生成する。

4.1 データ自動生成の考え方

多層 PCB の製造工程は以下の加工工程は不可欠だ。

1. 材料準備
2. 材料表面の汚れや油分を除去し
3. パターン転写（一回にフォトリソグラフィ方式とダイレクト印刷方式どちらを選ぶ）
4. エッチングとレジスト除去（複数回加工する場合ある）
5. 積層（複数回加工する場合ある）
6. ドリル加工

7. スルーホールめっき
8. ソルダーレジスト塗布
9. 表面処理
10. 電気検査
11. 包装

ここまでの加工ができましたら、出荷までの作業は終了とする。このような加工工程があって、加工機械に役割を割り当ては以下のように設定する。

表 2: 加工機械および工程内容の定義

機械番号	工程内容
M_1	銅箔付きの絶縁板 1 を取る
M_2	銅箔付きの絶縁板 2 を取る
M_3	表面の汚れや油分を除去する
M_4	パターン転写 (フォトリソグラフィ方式)
M_5	パターン転写 (ダイレクト印刷方式)
M_6	エッチングおよびレジスト除去
M_7	積層
M_8	ドリル加工
M_9	スルーホールめっき
M_{10}	ソルダーレジスト塗布
M_{11}	表面処理
M_{12}	電気検査
M_{13}	包装

本研究は 6 種類の製品が生産可能な工場と仮定する。この 6 種類の製品の加工工程順序は以下のように設定する。

$$OM = \begin{bmatrix} 1 & 3 & 4 & 6 & 7 & 8 & 9 & 10 & 11 & 12 & 13 & 0 & 0 & 0 & 0 & 0 & 0 \\ 2 & 3 & 5 & 6 & 7 & 8 & 9 & 10 & 11 & 12 & 13 & 0 & 0 & 0 & 0 & 0 & 0 \\ 1 & 3 & 4 & 6 & 5 & 6 & 7 & 8 & 9 & 10 & 11 & 12 & 13 & 0 & 0 & 0 & 0 \\ 2 & 3 & 5 & 6 & 4 & 6 & 7 & 8 & 9 & 10 & 11 & 12 & 13 & 0 & 0 & 0 & 0 \\ 1 & 3 & 5 & 6 & 4 & 6 & 7 & 8 & 9 & 4 & 6 & 10 & 11 & 12 & 13 & 0 & 0 \\ 2 & 3 & 5 & 6 & 4 & 6 & 7 & 8 & 9 & 4 & 6 & 5 & 6 & 10 & 11 & 12 & 13 \end{bmatrix}$$

この OM 行列はジョブセット各加工工程機械割り当ての行列、 $OM_{s,q} = \{1, 2, \dots, 12, 13\}$ ということは製品 s の第 q 番目加工工程の加工機械は $OM_{s,q}$ である。 $OM_{s,q} = 0$ の場合、製品 s の第 q 番目加工工程自体はないことだ。

エッチングとレジスト除去、積層、スルーホールめっき、この三つの加工操作は PCB をまとめて操作可能な加工工程のことで、加工時間は定値に設定する。この三つの加工工程を除いて、他すべての加工工程の加工時間は $n_s \times$ 単位時間 の積だ。次は各機械の単位加工時間もしくは定値加工時間を設定する。

表 3: 加工機械別加工時間パラメータの設定

加工時間パラメータ	設定値
MT_1	0.5 (単位加工時間)
MT_2	0.5 (単位加工時間)
MT_3	2 (単位加工時間)
MT_4	8 (単位加工時間)
MT_5	7 (単位加工時間)
MT_6	250 (基準加工時間)
MT_7	600 (基準加工時間)
MT_8	3 (単位加工時間)
MT_9	750 (基準加工時間)
MT_{10}	5 (単位加工時間)
MT_{11}	4 (単位加工時間)
MT_{12}	3 (単位加工時間)
MT_{13}	1 (単位加工時間)

次に受注数およびロット数のばらつきを表現するために、受注数は平均 $\mu_{order} = 10$ 、分散 $\sigma_{order}^2 = 2$ の正規分布に従う乱数から生成し、ロット数は平均 $\mu_{lot} = 3$ 、分散 $\sigma_{lot}^2 = 1$ の正規分布に従う乱数から生成する。負の値および 0 は現実的でないため除外し、正の値のみを採用する。

表 4: オーダー数およびロット数に関する確率分布パラメータ

パラメータ	説明
μ_{order}	総オーダー数の平均値
σ_{order}^2	総オーダー数の分散
μ_{lot}	各オーダーに注文された製品ロット数の平均値
σ_{lot}^2	各オーダーに注文された製品ロット数の分散

これにより、実際の生産現場に見られる受注量とロットサイズのゆらぎを簡易的に表現する。

各注文には、最大 6 種類の製品種別が含まれ得るものとし、確率 $P = 0.7$ で当該製品が注文に含まれると仮定する。これにより、オーダーごとの製品構成行列 $order$ を生成し、各製品種別ごとの総注文件数 n_s はロット数の合計に基板 1 ロットあたり 10 枚という仮定を掛け合わせて算出する。その後、各加工工程の処理時間は、この n_s と機械別の単位加工時間または基準加工時間パラメータに基づいて決定する。例えば、ドリル加工や電気検査など加工時間が枚数に比例すると考えられる工程では、 $n_s \times MT_m, m = \{1, 2, 3, 4, 5, 8, 10, 11, 12, 13\}$ で工程時間を設定し、一方、エッチングや積層などバッチ処理的な工程では、製品枚数に依存しない基準時間 $MT_m, m = \{6, 7, 9\}$ を用いる。こうして得られた処理時間行列が、行列 OT に相当する。

$$OT_{s,q} = \begin{cases} n_s * MT_m & m \in \{1, 2, 3, 4, 5, 8, 10, 11, 12, 13\} \\ MT_m & m \in \{6, 7, 9\} \end{cases} \quad (5)$$

以上のように、本研究の自動生成データは、

1. 多層プリント基板の代表的な加工工程列を反映した機械割当行列 OM
2. 受注数・ロット構成のばらつきと機械特性を考慮して決定される処理時間行列 OT

から構成され、実工場の特徴を保ちつつ、パラメータを変えることで多様な実験用ジョブセットを大量に生成できるように設計している。

4.2 データ生成手続き

具体的なデータ生成手続きは、Python により実装したプログラムに従って以下の手順で行う。

1. 乱数 seed $seed_{value}$ を設定し、受注数およびロット数の正規分布パラメータ、機械別単位加工時間・基準加工時間パラメータを初期化する。
2. 生成するジョブセット数を $gene = 10000$ とし、 $gene = 0, \dots, gene - 1$ について以下の処理を繰り返す。
3. 受注数の候補として、平均 μ_{order} 、分散 σ_{order}^2 の正規分布からサンプルサイズ $order_{size}$ 個の乱数系列を生成し、0 以下の値を除外する。その中から 1 つをランダムに選択し、実際の受注数 $order_{number}$ とする。
4. 同様に、ロット数についても平均 μ_{lot} 、分散 σ_{lot}^2 の正規分布からサンプルサイズ lot_{size} 個の乱数系列を生成し、0 以下を除外した上でロット数候補集合を得る。
5. 受注数 $order_{number}$ と製品種類数 6 に基づき、オーダー原始データ行列 $order$ (サイズ $order_{number} \times count_{type}$) を初期化する。各注文 O_i と製品種別 J_s について、確率 $P = 0.7$ で当該製品が注文に含まれるとし、含まれる場合にはロット数候補集合から 1 つをランダムに選択して $order_{i,s}$ に代入する。
6. 行列 $order$ の列方向の合計に基板 1 ロットあたり 10 枚を乗じることで、各製品種別ごとの総基板枚数ベクトル $product_{count}$ を算出する。
7. 各製品種別 J_s および各工程番号 q について、機械割当行列 OM の要素 $OM_{s,q}$ を参照し、その値に応じて処理時間行列 $OT_{s,q}$ を決定する。枚数に比例する工程では $product_{count}[s]$ と単位時間を乗じ、バッチ処理工程では基準時間をそのまま用いる。
8. 行列 OM および OT をもとに、行列 $JOBSET$ を作成する。 $JOBSET$ は行方向に製品種別 (製品 1～製品 6)、列方向に工程番号 (加工工程 1～加工工程 17) を取り、各要素には「(機械番号, 加工時間)」の組を文字列として格納する。これにより、 $JOBSET$ の機械番号部分が OM 、加工時間部分が OT に対応する。
9. 生成条件 (分布種別、受注数分布パラメータ、ロット数分布パラメータ、使用機械数、シード値) に基づいて出力ディレクトリおよびファイル名を構成し、 $JOBSET$ を .csv 形式で保存する。

そして同じジョブの作業について、前作業と後作業があり、作業の前作業と後作業のどれかの作業機械は一致しないと設定する。

$$\begin{cases} \text{before}\{m_{s,q}\} \neq m_{s,q} \\ \text{after}\{m_{s,q}\} \neq m_{s,q} \end{cases} \quad (6)$$

4.3 データ生成結果

先節で述べた通りに 10000 個のデータを実際に生成した。この中から 121 個を選択し、一つずつジョブセットの中にすべての加工工程の加工時間の分散を計算し、分散の大きさを基準として、三分位で注文書を小さい注文、一般注文と大きい注文に分けてラベルつける。選択されたデータを次章の実験で利用する。

id	分散	タイプ	40	210131.65	一般注文	81	162248.8	小さい注文
0	291969.24	一般注文	41	411175.81	大きい注文	82	380666.39	大きい注文
1	599314.24	大きい注文	42	138922.01	小さい注文	83	78159.49	小さい注文
2	319267.09	一般注文	43	182554.24	小さい注文	84	229245.53	一般注文
3	188772.75	一般注文	44	201636.06	一般注文	85	299946.27	一般注文
4	294717.66	一般注文	45	63946.44	小さい注文	86	344938.76	大きい注文
5	110509.24	小さい注文	46	597108.72	大きい注文	87	370693.73	大きい注文
6	247450.44	一般注文	47	301417.72	一般注文	88	364219.22	大きい注文
7	260110.28	一般注文	48	327616.44	大きい注文	89	130341.63	小さい注文
8	324851.89	一般注文	49	251280.34	一般注文	90	388925.06	大きい注文
9	188229.49	小さい注文	50	150776.23	小さい注文	91	258825.81	一般注文
10	188604.81	小さい注文	51	245016.77	一般注文	92	257119.68	一般注文
11	152457.34	小さい注文	52	343285.68	大きい注文	93	392275.28	大きい注文
12	672143.73	大きい注文	53	190369.68	一般注文	94	176454.68	小さい注文
13	102620.49	小さい注文	54	185743.92	小さい注文	95	432331.39	大きい注文
14	131368.97	小さい注文	55	155210.91	小さい注文	96	283358.84	一般注文
15	171182.26	小さい注文	56	130460.12	小さい注文	97	113377.07	小さい注文
16	272638.45	一般注文	57	339203.95	大きい注文	98	144882.4	小さい注文
17	292861.52	一般注文	58	365846.14	大きい注文	99	188579.98	小さい注文
18	236118.57	一般注文	59	270086.07	一般注文	100	379744.05	大きい注文
19	182211.52	小さい注文	60	343895.57	大きい注文	101	292252.14	一般注文
20	391714.39	大きい注文	61	409258.35	大きい注文	102	305206.57	一般注文
21	209852.97	一般注文	62	312287.02	一般注文	103	626685.43	大きい注文
22	205242.88	一般注文	63	370204.37	大きい注文	104	159087.5	小さい注文
23	366097.62	大きい注文	64	139458.61	小さい注文	105	356260.74	大きい注文
24	386418.16	大きい注文	65	148883.48	小さい注文	106	380604.03	大きい注文
25	405648.95	大きい注文	66	265197.71	一般注文	107	100954.11	小さい注文
26	89952.37	小さい注文	67	569503.32	大きい注文	108	397146.19	大きい注文
27	331673.7	大きい注文	68	301312.64	一般注文	109	109580.38	小さい注文
28	224600.76	一般注文	69	106459.81	小さい注文	110	182487.72	小さい注文
29	129098.16	小さい注文	70	297568.34	一般注文	111	376685.34	大きい注文
30	394861.39	大きい注文	71	442687.81	大きい注文	112	137131.08	小さい注文
31	592042.46	大きい注文	72	325593.35	一般注文	113	119496.01	小さい注文
32	168737.83	小さい注文	73	612936.46	大きい注文	114	163610.74	小さい注文
33	253819.68	一般注文	74	387869.48	大きい注文	115	295326.65	一般注文
34	299788.45	一般注文	75	120853.66	小さい注文	116	115524.36	小さい注文
35	106247.96	小さい注文	76	331364.62	大きい注文	117	347402.52	大きい注文
36	326180.19	大きい注文	77	484482.24	大きい注文	118	352087.02	大きい注文
37	199461.7	一般注文	78	324833.29	一般注文	119	420986.01	大きい注文
38	244235.5	一般注文	79	183299.36	小さい注文	120	314926.07	一般注文
39	210356.64	一般注文	80	170159.77	小さい注文			

図 2: データ分類

5. 遺伝的アルゴリズムによる解の改善

本研究では、JSSP に対して、GA を用いた探索手法を採用する。また、こういう加工順序が厳格に定められている問題には、PPS(Precedence Preservative Crossover) という交差手法を採用します。

5.1 遺伝的アルゴリズムの考え方

本研究では、JSSP に対して、ジョブごとの工程順序を厳密に保持しつつ、複数の製品に属する加工工程の加工順序を染色体として表現する遺伝的アルゴリズム (GA) を用い、解の改善を行う。

まず、注文書であるジョブセットの各製品ジョブ J_s の加工工程列は、機械割当行列 OM および加工時間行列 OT に基づいて保存する。1 つのジョブは、「使用機械 $m_{s,q}$ と加工時間 $t_{s,q}$ の組からなる工程」として表現される。染色体は、すべてのジョブに属する各工程を一度ずつ含む遺伝子列

$$\text{genes} = [J_s F_q, J_{s'} F_{q'}, \dots]$$

として定義され、各遺伝子は「ジョブ J_s の第 q 工程」を表す。スケジュールの手順について、遺伝子列に従って工程を順に配置し、同一製品ジョブ内の工程順序制約および各機械が同時に 1 工程しか処理できないという資源制約のもとで処理開始時刻と終了時刻を更新することにより、スケジュール全体の総加工時間を算出する。

初期解は、各製品ジョブ内の加工工程順序を保つままランダムで遺伝子列に導入する方法によって生成する。具体的には、各ジョブについて「次に処理すべき工程インデックス」を管理し、未処理工程を有するジョブの集合からランダムに 1 ジョブを選択し、そのジョブの次の加工工程を遺伝子列の末尾に追加する操作を繰り返す。この手続きを全ジョブの全加工工程が配置されるまで継続することで、すべての工程を一度ずつ含み、かつ製品ジョブ内の加工工程順序が必ず守られた初期解が得られる。

GA の適応度評価は、各染色体が表現するスケジュールの品質を定量的に評価するために行われる。本研究では、JSSP における代表的な性能指標である総加工時間を評価基準として採用する。各染色体が示す遺伝子列をスケジュールへとデコードし、製品ジョブ内の工程順序制約および機械資源制約を満たす実行計画を構成した上で、対応する総加工時間を算出することで、解の良さを比較する。

適応度評価では、各染色体に対してスケジュールを配置し、対応する総加工時間を適応度として計算する。本研究では総加工時間の最小化を目的とするため、適応度は値が小さいほど良好な解であることを意味する。計算された総加工時間は染色体オブジェクト内に保存され、同一染色体に対する重複総加工時間計算を避けることで、計算効率の向上を図っている。

親個体の選択にはトーナメント選択を採用する。許容解集団からランダムに複数個体（本研究では 5 個体）を抽出し、その中で総加工時間が最小の個体を勝者として選択する操作を 2 回行うことで、二つの親染色体を決定する。この選択方式により、適応度の高い個体が次世代に残りやすくなる一方で、一定のランダム性が維持され、探索の多様性が確保される。

GA で二つの親から特徴を継承し子個体を生成するためには、交叉操作が必要です。交叉操作には、PPS(Precedence Preservative Crossover) と呼ばれる順序保持型の交叉手法を用いる。この交叉手法の紹介は次章で述べます。生成後は染色体修復処理を行う、加工工程の欠落や重複が生じないように解の有効性を保証する。

また、本研究の GA ではエリート保存戦略を採用している。各世代において総加工時間が最小となる個体から、あらかじめ定めた個数（本研究では 2 個体）を次世代集団へそのまま引き継ぐことで、進化の過程で得られた最良解が失われることを防止する。残りの個体は、選択・交叉操作によって生成された子個体で構成され、所定の最大ジェネレーション世代数（本実装では 200 世代）に達するまで進化計算を繰り返す。最終的に、全ジェネレーション世代を通じて得られた最良染色体を GA の解として採用し、対応するスケジュールについて甘特図と各ジェネレーション世代にもっとも短い総加工時間の折れ線グラフを描画することで、視覚的な評価も行う。

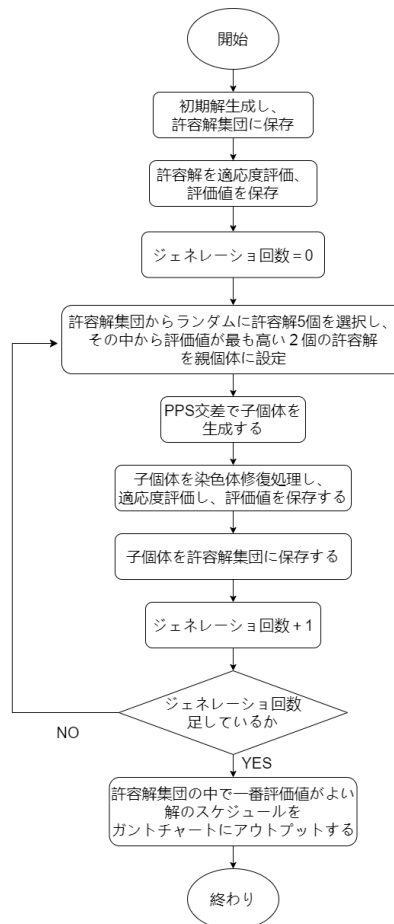


図 3: 遺伝的アルゴリズムフローチャート

5.2 PPS 交叉法の考え方

PPS 交叉法は、JSSP 問題などの順序制約を伴う組合せ最適化問題において有効な交叉手法の一つである。本手法は、親個体の遺伝子列情報を交叉する際に、工程間の優先順序を保持しつつ、新たな子個体を生成することを目的としている。

これから、PPS の交叉手順を紹介します。

1. 2 つの親染色体 (Parent1, Parent2) を許容解集団から選択する。

2. Parent1 と Parent2 から操作配列を主に利用する。
3. 子個体の染色体を初期化する。
4. Parent1 と Parent2 をランダムに選択する。選択された親個体の頭から、選択されない操作を子個体操作配列の最後に挿入する。
5. すべての操作が配置されるまで繰り返す。

数式：

- $J = \{J_1, J_2, \dots, J_s\}$ ：製品種類の集合
- 各製品 J_s は q 個の加工操作を持ち、 $F_q = \{J_s F_1, J_s F_2, \dots, J_s F_q\}$ とする。
- 親個体は操作列として表現される： $P_1 = [o_1^1, o_2^1, \dots, o_\theta^1]$, $P_2 = [o_1^2, o_2^2, \dots, o_\theta^2]$
- 親個体の頭からまだ子個体に配置していない操作： $P_1 o \in [o_1^1, o_2^1, \dots, o_\theta^1], P_1 o \notin C$ 、 $P_2 o \in [o_1^2, o_2^2, \dots, o_\theta^2], P_2 o \notin C$
- 子個体 C を空列として初期化： $C \leftarrow []$

1. $i \leftarrow 1$
2. **while** $|C| < \theta$ **do**:
 - (a) $Po = \text{random}\{P_1 o, P_2 o\}$
 - (b) $C \leftarrow Po$
 - (c) $i \leftarrow i + 1$
3. **return** C




図 4: PPS フローチャート

参考文献

- [1] K.T. Chung, C.K.M.Lee and Y.P. Tsang, "Neural combinatorial optimization with reinforcement learning in industrial engineering: a survey" *Artif Intell Rev.* vol. 58, 130(2025).
- [2] M. Xu, Y. Mei, F.F. Zhang and M.J. Zhang, "Learn to optimise for job shop scheduling: a survey with comparison between genetic programming and reinforcement learning" *Artif Intell Rev.* vol. 58, 160(2025).
- [3] C. Ngwu, Y. Liu and R. Wu, "Reinforcement learning in dynamic job shop scheduling: a comprehensive review of AI-driven approaches in modern manufacturing" *J Intell Manuf.*(2025).
- [4] X.R. Shao and C.S. Kim, "An Adaptive Job Shop Scheduler Using Multilevel Convolutional Neural Network and Iterative Local Search" *IEEE Access.* vol. 10, pp. 88079-88092(2022).
- [5] L.B. Wang, X. Hu, Y. Wang, S. Xu, S. Ma, K. Yang, Z. Liu and W. Wang, "Dynamic job-shop scheduling in smart manufacturing using deep reinforcement learning" *Computer Networks.* vol. 190, 107937(2021).
- [6] S. Lee, Y. Cho and Y.H. Lee, "Injection Mold Production Sustainable Scheduling Using Deep Reinforcement Learning" *Sustainability.* vol. 12, 8718(2020).
- [7] C. Pickardt, J. Branke, T. Hildebrandt, J. Heger and B. Scholz-Reiter, "Generating dispatching rules for semiconductor manufacturing to minimize weighted tardiness" *Proceedings of the 2010 Winter Simulation Conference.*Baltimore, MD, USA, pp. 2504-2515(2010).
- [8] 村山 昇, 川田 誠一, "遺伝的アルゴリズムを用いた加工機械と複積載 AGV の同時スケジューリング" 日本機械学会論文集 (C 編). vol. 12, 712, pp. 3638-3643(2005-12).
- [9] B. Yu, Z. Hui, Z. Xin, C. Zheng, J. Riku, Y. Kun, "Toward Autonomous Multi-UAV Wireless Network: A Survey of Reinforcement Learning-Based Approaches" *IEEE COMMUNICATIONS SURVEYS AND TUTORIALS.* vol. 25, No. 4, FOURTH QUARTER 2023, pp. 3038-3067(2023).
- [10] 小野 啓介, 森川 克己, 長沢 敬祐, 高橋 勝彦, "フレキシブルジョブショップ環境の受託製造企業におけるエネルギー消費量配分問題" *J Jpn Ind Manage Assoc.* vol. 72, pp. 179-187(2022).
- [11] 貝原 俊也, 國領 大介, 藤井 信忠, 村上 亘, 梅田豊裕, "フレキシブルジョブショップを対象とした受注生産における機械稼働計画立案のための基礎検討" 第 63 回自動制御連合講演会. (2020).
- [12] 貝原 俊也, 國領 大介, 藤井 信忠, 西村 翔平, "CPS 型ファクトリセキュリティ実現に向けた生産スケジューリング手法に関する研究-マスカスタム生産対応フレキシブルオープンショップを対象とした検討-" 第 61 回自動制御連合講演会. (2018).
- [13] 平沼 智之, 安田 翔也, 藤堂 健世, 谷口 茉帆, 山村 雅幸, "組合せ最適化ぬおけるベイジアン最適化アルゴリズムを組み込んだ遺伝的アルゴリズムの提案" *The 35th Annual Conference of the Japanese Society for Artificial Intelligence.* (2021).
- [14] 三神 賢雅, 伊原 滉也, 佐久間 拓人, 加藤 昇平, "混合整数最適化に基づく生産ライン作業スケジュール生成システムの開発" *The 36th Annual Conference of the Japanese Society for Artificial Intelligence.* (2022).
- [15] 蘭 嘉, 田中 瑛理, 佐々木 優, 森江 翔, 有馬 澄佳, "複数種のリソースを共用する多品種生産システムの分散協調スケジューリング-自動車部品後補充生産への適用-" 日本経営工学会論文誌. vol. 72, No.1, pp. 75-87(2021).
- [16] G.Y. Shi, H. IIMA, N. Sannomiya, "A New Encodnig Scheme for Solving Job Shop Problems by Genetic Algorithm" *Conference on Decision and Control.* (1996).
- [17] UMIT BILGE, GUNDUZ ULUSOY, "A TIME WINDOW APPROACH TO SIMULTANEOUS SCHEDULING OF MACHINES AND MATERIAL HANDLING SYSTEM IN AN FMS" *Operations Research.*vol. 43, No.6, (1995).
- [18] 花田 良子, 廣安 知之, 三木 光範, "遺伝的アルゴリズムによる工場の生産スケジュールの自動生成" *THE SCIENCE AND ENGINEERING REVIEW OF DOSHISHA UNIVERSITY.*vol. 48, No.4, pp.241-248, (2008).
- [19] 平中 雄一朗, 西 竜志, 乾口 雅弘, "ラグランジュ緩和とカット生成による生産工程と複数台搬送車の同時スケジューリング問題に対する分解法" システム制御情報学会論文誌.vol. 20, No.12, pp.465-474, (2007).
- [20] Raghda B. Taha, Amin K. El-Kharbotly, Yomna M. Sadek, Nahid H. Afia, "A Genetic Algorithm for solving two-sided assembly line balancing problems" *Ain Shams Engineering Journal.*vol. 2, pp.227-240, (2011).
- [21] Kazi Shah Nawaz Ripon, N. H. Siddique, Jim Torresen, "Improved precedence preservation crossover for multi-objective job shop scheduling problem" *Evolving Systems.*vol. 2, pp.119-129, (2011).

-
- [22] Andrzej Kiernich, Jerzy Kalenik, Wojciech Steplewski, Marek Koscielski and Aneta Cholař, "Impact of Particular Stages of the Manufacturing Process on the Reliability of Flexible Printed Circuits" *Sensors*.25, 140, (2025).
- [23] 斎藤 康毅, 『ゼロから作る Deep Learning - Python で学ぶディープラーニングの理論と実装』, オライリー・ジャパン,2022.
- [24] 野寺 隆志, 『楽々LATEX』, 共立出版株式会社,1996.
- [25] 飯塚 修平, 『ウェブ最適化ではじめる機械学習』, オライリー・ジャパン,2020.
- [26] 矢沢 久雄, 『基本情報技術者 らくらく突破 Python』, 技術評論社,2021.
- [27] 伊藤 多一, 今津 儀充, 須藤 広大, など 『現場で使える! Python 深層強化学習入門 - 強化学習と深層学習による探索と制御』, 株式会社翔泳社,2025.
- [28] Kirill Bobrov, 『なっとく! 並列処理プログラミング』, 株式会社翔泳社,2025.
- [29] 平井 有三, 『はじめてのパターン認識』, 森北出版株式会社,2023.
- [30] 大用 倉智, 山田 孝子, 『作りながら丁寧に学ぶ Python プログラミング入門』, 関西学院大学出版会,2022.